全栈仿真：让网络等待回到推理服务

目标：解释 MoE 跨机通信为何拖慢 Decode，并比较等资源优化方案



实际完成事件反馈：多个副本共用同一持续网络，网络等待改变后续进度

已有验证

真实路由： 4 卡 / 2 机 / 2Pod，两层两步
规模： 128 卡单 EP； 256/512 卡多 EP4 副本

关注的网络结果

Dispatch/Combine 等待 → Decode 步长
固定任务与资源，定位 NIC 及各层交换出口

当前范围： KV 已就绪的 Decode；计算为声明成本；千卡两次超时，尚未验收。

拟增加细节：从流量热点走向网络机制

优先深化 Scale-Out 网络：先证明瓶颈，再选择一种优化机制

拟补细节	在现有基础上增加什么	要回答的问题
01 路由与通信组织	扩展真实样本与热点时序；补目的节点去重、 机内汇聚—跨机—机内分发，计入准备 / 转发成本。	热点是否跨机集中？ 分层通信能否减少等待？
02 连接与分层容量	已有 Clos/rail/plane 输入；补共享 NIC 与跨 rail 中继， 明确 GPU 亲和、逐层带宽与等资源分流。	瓶颈在哪个共享出口？ 多路径何时有效？
03 协议等待与归因	已有完成回调与摘要；补有界队列时序、 PFC/ECN 反馈和慢轮次的关键依赖链。	慢在发送、排队还是确认？ 哪段等待真正拖慢服务？
04 校准与规模效率	补匹配 A100/H100 及消息形状的测量； 拆分构图、执行与写出成本，再验收千卡。	预测与实机相差多少？ 千卡能否在预算内完成？

验证路径：真实 / 打乱 / 均匀路由 + 等容量放置 + 固定带宽预算

先做小图机制对照，再做硬件校准与代表性规模验证；拟增细节不作为已完成能力。