MoE 推理全栈联合仿真

Scale-Up 与 Scale-Out 网络研究

汇报人：李润宇

研究方向：MoE 推理网络仿真

2026 年 10 月 20 日

全栈仿真：机内与跨机网络等待反馈

目标：解释 MoE 机内 / 跨机通信如何拖慢 Decode，比较等资源优化方案



两条后端分别执行；各自的完成事件反馈下一轮推理进度

已有验证

Scale-Up： 128 卡真实路由完整首轮
Scale-Out： 4 卡 R1 片段； 128/256/512 卡

关注的网络结果

机内：端侧发送、 UB 信用与出口队列
跨机： NIC/Clos/rail 与 Decode 等待

范围：两后端隔离，计算仍需校准； Scale-Out 千卡两次超时，尚未验收。

拟增加细节：机内与跨机网络机制

Scale-Up 与 Scale-Out 共同关注：先证明关键等待，再选择优化机制

拟补细节	在现有基础上增加什么	要回答的问题
01 专家流量与通信	UB：核查 STORE/LOAD 及响应拆分； RDMA：保留热点时序， 研究机内汇聚—跨机—机内分发，计入转发成本。	热点在哪层形成等待？ 通信组织何时有效？
02 连接与分层容量	机内：端口、发送槽、信用；跨机：已有 Clos/rail， 补共享 NIC、 GPU 亲和及跨 rail 中继。	瓶颈在哪个共享出口？ 等资源分流何时有效？
03 协议等待与归因	UB 已有端侧 / 队列记录； RDMA 已有回调与摘要， 补有界时序，关联信用、 ECN/PFC 及关键前驱。	慢在发送、排队还是反馈？ 哪段等待拖慢服务？
04 校准与规模效率	区分 UB/RDMA 硬件和软件条件，补形状匹配测量； 拆分构图、执行和写出成本，再验收千卡。	模型预测误差多大？ 扩规模能否在预算内完成？

验证路径：两后端各做真实 / 打乱 / 均匀路由 + 等资源机制对照

先追踪机内 / 跨机关键等待，再做硬件校准与规模验证；拟增能力尚未实现。