小规模 Scale-Out 联合仿真实验方法

审阅稿 v0.1 · 2026-10-15 · 实验尚未启动

1. 本次要证明什么

建立从 LLMServingSim 请求与组批，到 ASTRA 依赖图，再到非 UB ns-3 分组网络的全流程。用小规模实验回答：batch、跨 Pod 汇聚和 rail / plane 结构怎样改变 MoE 通信的排队与阶段完成时间，以及这些等待怎样传回服务调度。

首轮采用 8 个 GPU 逻辑端点、4 台双卡服务器。先证明通信与计算之间的事件因果关系，再解释网络现象；千卡、完整训练、真实模型精度与生产容量不作为本轮结论。

2. 建议审阅的默认范围

项目	拟采用方法
业务	ready-KV 的 MoE Decode；每序列每步产生 1 个 query token
模型	合成 MoE 层：H=1024、F=4096、16 专家、Top-K=2、激活 2 B；主实验 1 层，闭环验收 2 层
规模	8 端点 / 4 服务器 / 2 Pod；EP=8，TP=PP=1
网络	主线复用锁定 ASTRA 的原生 RDMA ns-3；阿里库只作独立语义核查
重点	batch、分层带宽、跨 Pod 路径、单/双平面和专家热点
不纳入首轮	Prefill、KV 迁移、训练梯度同步、完整 HPN 协议、自动故障切换

3. 已有基础与尚缺能力

已有：可参数化拓扑生成、两种原生文本导出、NIC 映射和可达性审计；既有 23 项相关检查通过，千卡输入只做过静态生成。

尚缺：原生拓扑装载验收、与服务调度连接的非 UB 后端、适用于 RDMA 的消息生成与完成事件适配、分平面选路及网络指标导出。既有 CANN/UB 通信模板不能仅更换网络文件就当成通用 RDMA。

> 审阅重点：是否认可“8 卡 Decode → 打通事件闭环 → 网络对照”的顺序，以及先用声明的计算成本研究网络机制。全文参数与实验矩阵均为拟实施方案，不是已经取得的实验结果。

从前端到网络后端的完整流程

1. 业务图与网络执行分工



LLMServingSim 的 Scheduler、请求与 KV 状态决定本轮参与序列和 token；中间表示记录计算节点、逻辑通信及依赖；ASTRA 按数据依赖推进节点；唯一一套非 UB ns-3 执行共享的 NIC、链路、队列及协议状态。波次完成后返回前端，更新请求进度并形成下一轮 batch。

固定图重放用于早期排错；最终验收必须跑到下一轮调度，不能用一次离线流量回放代替全流程。Python 构图的宿主耗时不进入仿真时钟。

2. 前端究竟生成什么 trace

记录	必需内容与用途
请求与路由	request / token / layer、context 长度、源 rank、所选专家、来源与 seed
计算 DAG	node_id、rank、声明的 duration_ns、前驱；保留 pack、expert、merge 等阶段
逻辑消息	run/group/wave/layer/message_id、src/dst、payload_bytes、前驱节点、分块和聚合身份
映射与配置	专家→rank→GPU→server、可用 NIC/rail/plane、分层网络参数、版本与 hash

这些是依赖和消息描述，不是固定发送时刻表。消息只在前驱实际完成后注入；ns-3 再分成数据包。trace 不预置 FCT、队列长度或“网络结束时间”。Chakra 表达是否覆盖所需消息身份，须在接入阶段逐项核对。

3. 必须守住的事件语义

同一逻辑消息只发送一次；RECV 负责等待，不再发送一份。区分提交发送、末字节到达、ACK 确认与发送资源回收。消费者只能在声明的数据可用事件之后启动；释放发送资源不能冒充接收就绪。

若原生接口首轮只能提供 ACK 完成，采用 ACK 放行的保守模型并明确标注，不能声称精确模拟更早的接收计算重叠。阿里库已发现的按包长触发 SendComplete 的重复/缺失路径不得直接作为业务完成依据。

> 全部 EP 组共享同一网络执行与时钟；禁止独立跑各组、各层或 scale-up / scale-out，再将时延相加。

输入参数与 MoE 通信量定义

1. 负载、GPU 与计算成本

主实验层使用 16 个 routed experts、无 shared expert；H=1024，FFN 中间维 F=4096，Top-K=2，激活采用 FP16/BF16 的 2 B 逻辑尺寸。按三矩阵 gated FFN 粗算，仅专家权重约 0.201B 参数 / 384 MiB，不代表完整语言模型的大小。

GPU 标签设为 A100，目标设备可描述为 A100 80GB；本轮不实际执行 GPU 数值前向，也不宣称拥有完整 A100 算子校准。计算时间使用显式参考表，记录形状、dtype 和来源；已有 A100 H=256 小形状测量不能外推到 H=1024 或完整 MLA。

每序列初始 context=2048，KV 预先就绪；先运行 4 次 Decode，首步作为启动检查，其余 3 步展示有限窗口。单层结果叫“层/阶段完成时间”；只有具备完整 token 依赖与服务回传，才报告相应服务时间。输入 context 不等于本次传输 token 数。

2. batch 与通信矩阵

B 明确定义为每 rank 每波次的活跃序列数，取 1 / 4 / 16。EP=8 时全组每步分别产生 8 / 32 / 128 个 token，不使用含糊的“batch=4”代替两者。

首版固定 per-expert-copy 语义：同一 token 选择的专家不能重复，但落在同一目的 rank 的不同专家仍分别计一次贡献；可聚合成消息，不跨专家去重。初版不用 CANN 动态量化、UB 状态消息或 DeepEP rank 去重行为冒充通用 RDMA。

对象	定义
C[i,j]	源 rank i 的 token 中，目标专家位于 rank j 的选择次数
Dispatch[i,j]	i≠j 时，C[i,j] × H × 2 B；i=j 走本地路径
Combine[j,i]	对应专家结果返回源 rank，初版每贡献也按 H × 2 B
网络总量	分别统计远程 payload、跨服务器/Pod payload、包头、ACK 与重传

B=4 时全部专家贡献的 Dispatch 逻辑量为 8×4×2×1024×2=131072 B；其中含本地项，实际网络 payload 必须减去本地项，不能直接当作注入量。Combine 的逻辑贡献量同口径。

3. 路由来源与 EP 分组

均衡病例用可复现的专家选择多重集；热点病例规定 50% token 包含专家 0，并保证 Top-K 不重复。它们均标记 synthetic，不能作为真实训练热点结论。用户所给 HF 原始数据待可用后再做独立扩展。

EP=4 对照使用两个独立推理副本组，保持全局序列数与 16 专家/副本不变，显式记录专家放置与远程字节。副本数增加会改变模型占用和通信，不能声称“只改了 EP”；本轮不执行训练 DP 梯度 AllReduce。

小规模拓扑与带宽配置

1. 用同样的 8 端点覆盖结构

全部采用 2 Pod × 每 Pod 1 Segment × 2 服务器 × 每服务器 2 GPU。T0/T1 的每 Segment/rail 有 2 ToR；T2/T3/T4 则每 GPU 槽对应 1 rail、每 Segment/rail 有 1 ToR。Core 全为普通电交换机。

编号	结构	ToR/Agg/Core	rail/plane	连接规则
T0	两层 leaf-spine	4 / 0 / 2	1 / 1	每 ToR 连全部 2 Core
T1	三层 Clos	4 / 4 / 2	1 / 1	每 ToR 连 2 Agg；每 Agg 连分组的 1 Core
T2	HPN参考单平面	4 / 2 / 1	2 / 1	Pod 内共享 Agg，跨 Pod 共享 Core
T3	HPN参考双平面	8 / 4 / 2	2 / 2	复制 T2 交换网络，每 NIC 同时接两 plane
T4	独立 multi-rail	4 / 4 / 2	2 / 1	Agg/Core 按 rail 隔离；禁止跨 rail 中继

以上数量由现有生成器参数推导，拟用于后续原生装载；不是已完成的网络运行。T4 在 EP=8 下预计有 16 个无序 GPU 对不可达，应在注入前拒绝；改为同 rail 的两个 EP=4 组，才进入可运行性检查。

2. 主线与公平对照

T0/T1/T2 的接入与上层链路均先设 100 Gb/s、每跳传播延迟 1000 ns；NIC 总预算 100 Gb/s。T1 带宽敏感性只改变 Agg→Core 为 100 / 50 / 25 Gb/s，其他字段固定。

T2 对 T3 时，单 plane 各层 100G；双 plane 各层每份 50G，单 NIC 合计仍为 100G，同时核对每层对应逻辑连接的合计容量。双 plane 的设备与队列数量不同，不视为严格等成本部署。按消息身份确定性选 plane，并记录策略；禁止依赖默认“第一张 NIC”来声称双平面生效。

若启用双平面流量分配，两平面都必须出现实际业务字节，消息不重复、不遗漏、不跨 plane 桥接。首版使用 flow-level 固定哈希，不增加 packet spray 或故障切换作为隐含变量。

3. 不能混淆的结构差异

T0、T1、T2 的路径、端口总量和超售不同，仅做机制剖析，不能直接将耗时排序归因于“哪种架构先进”。必须同时报告每交换机下/上容量比及实际跨 Pod 流量；只跑同 Pod 业务不能证明 Core 的作用。

服务器内 NVLink/PCIe 不在首轮物理网络中：同 GPU 的专家贡献走本地计算路径，不同 GPU 的通信按当前分组网络接线执行。结果只适用于这一部署假设，不当作真实八卡机器内通信性能。

对照矩阵与可证伪假设

1. 首轮安排：10 个有效配置，最多 30 次运行

默认 B=4、EP=8、均衡合成路由、同一参考计算表。各条件使用配对的 routing seeds 11 / 23 / 37，并固定记录网络 seed/run；复用相同基线，不重复计数。对照表是拟运行矩阵，尚无性能结果。

实验	改变因素	主要观测与判断	新增配置
E1 结构	T0 / T1 / T2	路径、实际瓶颈与阶段完成；不宣称等成本胜负	3
E2 batch	T1：B=1/4/16	payload、消息并发、队列与计算成本分别如何增长	2
E3 上联	T1：Core 上联100/50/25G	确认参数生效；区分出口服务不足与前端释放不足	2
E4 平面	T2单100G / T3双50G	固定总容量；验证双平面分流与哈希碰撞	1
E5 热点	T1：均衡 / 50% token选专家0	专家热度是否映射到 rank、链路及时间窗口热点	1
E6 EP分组	T1：EP8 / 两组EP4	保持总序列数；分开解释副本、远程比例与共享竞争	1

T4 的 EP8 拒绝和同 rail EP4 可达性作为功能验收，另列，不并入这 10 个性能条件。底层微实验也单独计数。先单条件通过再展开其余 seed；若预算耗尽保留已跑条件与失败原因，不把缺项写成通过。

2. 需要检验的解释

H1：上联受限会延后跨 Pod 消息及依赖它的 expert/merge。支持证据需同时出现该出口实际服务/排队、消费者后移；若流量不足或发送端额度先受限，单纯降低带宽可能没有明显影响，应据此修正解释。

H2：固定总带宽的双 plane 可能因路径与队列分散改变长尾，也可能因 flow 哈希不均或负载太小而无收益。先排除总带宽翻倍和只使用一 plane，才解释改善或退化。

H3：热点专家不必然导致最热网络链路。专家放置、源分布、跨 Pod 比例和时间聚集共同决定瓶颈。E5 的远程字节可能变化，必须分开报告；不能把其全部耗时差异归给排队。

H4：batch 增大时逻辑贡献量可按定义线性增加，但 payload 的本地比例、分块、计算和并发也会变；既不预设延迟同比增长，也不把定义推出的字节倍数当作创新发现。

> 阴性结果也是结果：没有排队、双 plane 无收益或热点未映射到 Core，都应说明限定条件，而不是继续调参保证预期现象出现。

观测指标与可视化交付

1. 业务、消息、端口三个层次

层次	必报指标	使用边界
服务/阶段	Dispatch、expert、Combine与波次完成；具备条件后报告逐token间隔	单层时间不冒充完整模型 TPOT；无 Prefill 不报告 TTFT
逻辑消息	payload、ready/start/receive/ACK时刻、FCT、完成次数	FCT 明确起止；排队等待与发送服务、传播、ACK分开
端口/队列	每方向数据与控制字节、利用率、队列曲线、最大值、ECN/PFC与重传	没有原生钩子的指标记“未采集”，不补造0
放置/热点	专家计数、rank入流、GPU/NIC及跨Pod矩阵、窗口峰均比	专家不均衡与链路不均衡是两类指标
资源/复现	宿主时长、RSS、产物大小、版本/配置hash、实际退出状态	宿主资源不等于模拟GPU容量

消息 FCT 默认从逻辑消息可注入时刻到声明的接收完成事件；另报首包/末包及 ACK 时刻以区分前端等待和网络等待。若只取得 ACK 回调，名称与分解口径必须改为 ACK 完成，不能沿用接收完成标签。

利用率按“该方向实际线上字节×8 / 端口速率 / 窗口长度”计算，数据、协议开销、重传分别列出。窗口默认 10 微秒，附 1 / 100 微秒的敏感性查看；实际阶段过短时同时展示事件曲线，避免平均值抹去突发。

2. 拟交付四类图

图 A：可展开 Pod / rail / plane 的拓扑，标每层数量、链路带宽、NIC映射和所选业务路径。颜色可切换为利用率或队列，明确图中数值来自哪个 run 和时间窗口。

图 B：rank→rank 与专家→rank 的热力图，分别展示 payload、跨 Pod比例和时间窗口热点。点击单元能定位对应消息集合，不能只给一张随机流量示意图。

图 C：Dispatch→expert→Combine 的执行时间线，对齐实际消息完成、消费者启动和瓶颈出口队列；用于解释等待如何传播，不把并行消息 FCT 相加当阶段延迟。

图 D：配对条件的完成时间、消息分布与分层负载。先给每次运行和样本数，再给汇总；确定性病例不通过无意义重跑制造误差条。三组路由seed只作基础敏感性，不支持生产p99或统计显著性的强结论。

3. 记录与算法输入

平台评价记录保留完整消息关联以核对因果；若后续研究诊断算法，算法仅使用声明开放的 observed，不能读取 truth 内部身份。网页/PDF图表只是读取已完成结果，不参与调度或网络决策。

> 可视化属于可选展示，但 CSV / JSON 原始指标、图表程序及输入映射必须可复现。审阅稿不放模拟结果曲线，以免示意数字被误认为已运行结论。

实施顺序、门槛与通过标准

G0：协议与物理输入先可信

先装载不超过 16 交换机的小图，核对节点、真实设备端口、rate/delay 与跨 Pod 路径。单消息覆盖 payload 1000 B 下的 999/1000/1001/3000 B，payload 9000 B 下的 8999/9000/9001/27000 B；另验双消息并发和可控重传。每逻辑消息恰好完成一次，无重传时 payload 守恒，有重传时逻辑与线上字节分开。

拥塞控制先选源码有实现的 DCQCN 模式 1，不继承未核实的 CC_MODE=12。PFC、ECN阈值、缓冲、headroom、MTU、ACK与窗口全部进入有效配置；50/100G均需有合法阈值映射。单流跑通后，再用汇聚微实验确认 ECN、速率变化或PFC实际生效，不能仅以配置名称作证。

G1：从 LLMServingSim 产生的图进入真实网络

保留请求身份、token与专家选择，生成中立的 Dispatch/Combine 消息与依赖，不把UB特有状态复制进RDMA。比较手算矩阵、图内贡献量、实际网络注入量及接收完成数，逐项核对本地与远程分量。

先完成固定图的小型真实执行，再引入在线控制。此门槛只证明业务图可执行，不单独宣布全流程完成。

G2：两层、两波次的在线闭环

使用至少 2 个连续 MoE 层、至少 2 次 Decode 波次，网络完成推进层内后继，并返回 LLMServingSim 更新请求状态/下一轮组批。两组EP并发时共用同一网络状态；结束后没有遗留消息、QP等待或未完成波次。

做同一业务输入的上联降速对照：固定计算节点耗时不变，发生变化的网络事件与消费者启动必须可追踪；不得预写下一波固定发送时刻。若采用 ACK 放行近似，单列其保守性并保留对应事件证据。

G3：开展 E1—E6，并解释机制

通过前述门槛后才展开矩阵。每个结论同时提供有效配置、通信矩阵、实际路径/端口负载、队列与阶段依赖证据。无法观测的等待保持未解释，不用结构超售比代替实际拥塞。

层次	本轮验收产物
平台	独立非UB构建目标、完成事件适配、公开运行/导出接口及小例
实验	有版本的条件配置、结果表、失败记录、因果分析与可复现图表
全流程证明	前端请求 → 图 → 单一ns-3 → 回调 → 下一轮服务的实际记录

> 任一门槛失败，停在该门槛修复平台并重跑受影响检查；不切换成理想网络、随机流量或多次独立仿真来满足“正常结束”。

复现、资源约束与审阅事项

1. 统一配置与代码布局

拟以单份实验配置关联 workload、model/profile、expert placement、topology、RDMA参数、seed及观测预算；先解析为全量有效配置，再生成并执行。统一脚本最终负责准备、运行、核验与分析，阶段可单独重跑，已有结果不覆盖。

平台通用能力放 python/moe_ub_cosim 与独立 RDMA 后端目标；第三方按固定提交放 third_party，阿里研究clone仍归 data/research。实验配置、执行矩阵和分析放 experiments/scaleout_e2e；大输入与结果放 data / runs；编译输出按后端隔离。平台与实验分开本地提交，不 push。

已有可用命令是 scaleout topology；统一的非UB运行命令和新 schema 尚待实现。本稿中的端到端接口是设计要求，不能当成现在已经可执行的命令。

2. 运行预算与当前限制

输入/分析检查拟限 300 秒、RSS 1 GiB、地址空间 2 GiB、产物 128 MiB；沿用独立构建的 300 秒、RSS 2 GiB/地址空间 4 GiB、并发2、来源/构建/本次日志累计512 MiB及磁盘预留8 GiB。小图网络单例拟限宿主60秒、RSS1 GiB/地址空间2 GiB、结果64 MiB，所有条件结果累计256 MiB，仿真时间最多5 ms；失败不得自动提高预算。

当前已有磁盘低于8 GiB预留的记录；实际开跑前重新检查。若仍不足则保持未运行，不删除未知文件。14交换机的固定计数数组约449 MiB只是下限推算，需叠加路由、队列和事件的实际RSS监测；资源不足先减少已声明场景，保留不满足目标的事实，不能称完整矩阵已完成。

构建与执行预算是本方案的拟使用上限，不是实测开销。每次保存固定依赖/源码摘要、有效输入、命令、退出状态、资源峰值和原始日志；功能通过、真实路由来源和硬件校准分别报告。

3. 请优先审阅这四点

1. 范围：先8卡Decode、参考计算成本与小型合成MoE层，完整模型和训练后续再扩展，是否符合近期研究目标？

2. 网络：先 ASTRA 原生 RDMA ns-3；HPN只取结构、Core用普通交换机；双平面固定合计带宽，是否认可？

3. 对照：先10个有效配置、最多30次主运行，并保留rail不可达和回调边界等独立功能检查，是否需要调整优先级？

4. 验收：先通过物理/协议门槛，再完成两层两波次在线闭环，最后做机制分析；审阅后再启动实施。

4. 依据与证据入口

仓库基线：25a93e5；拓扑功能：a879128。依据文件：docs/reviews/scaleout_ns3_backends_20261015.md、scaleout_topology_20261015.md、docs/model_validation.md；静态结果：experiments/scaleout_topology/results.json；回调探针：experiments/scaleout_backend_review/results.json。

HPN 论文 DOI：10.1145/3651890.3672265。结构参考用户提供图片和固定 SimAI 模板；未取得论文全文，不据此声称复现完整HPN。本文没有新增网络运行结果。