MoE Scale-Out 网络联合仿真实验方法

审阅稿 v0.4 · 2026-10-16 · 参数化拓扑、专家通信与规模成本

1. 研究要回答什么

MoE（混合专家模型）的专家分发与结果回收，会让不同 GPU 同时向多个目的地传输数据。本研究关注：这些通信在接入、汇聚、跨 Pod 出口或目的端哪里发生竞争；竞争怎样沿计算依赖拖慢 token 完成；改变网络结构、带宽或专家放置后，业务是否真正受益。

最终目标是形成一套可复现的网络实验平台：固定模型和路由后修改网络，固定网络后修改 batch、专家并行或放置，以逐消息、逐链路和业务完成事件解释结果，为 MoE 集群网络设计与优化提供证据。

2. 本稿的研究范围

对象	方法约定
服务	先研究 KV 已就绪的 Decode；每条活跃序列每步生成一个 token
通信	专家并行的 Dispatch / Combine，使用非均匀 All-to-All-v 字节矩阵
网络	普通电交换 Core；支持接入、Agg 汇聚、类 Clos，以及 multi-rail / 双平面结构的研究输入
执行	LLMServingSim → Chakra → ASTRA-sim → 非 UB ns-3；网络完成反馈推进下一轮
扩规模	分开评价物理图生成、实际业务执行、正确性和宿主等待成本

3. 审阅重点

请重点审阅：目标拓扑是否代表实际集群；网络对照是否公平；热点与跨 Pod 流量是否真实；各阶段产出能否回答明确问题。本文给出实验方法，不将尚未执行的对照写成研究结论。

> 相比 v0.3，本稿突出可配置拓扑与网络对照，补充宿主运行成本的测量方法。旧稿保留其生成时的历史状态；本稿不重复旧稿中已经过时的验收进度。

01 / 前端生成什么，后端执行什么



1. 输入是业务与依赖，不是预先写死的发包时刻

前端根据请求、KV 状态、batch 和专家选择生成每轮任务：包括计算节点、逻辑消息、消息大小及前驱依赖。Chakra 保存任务图，ASTRA-sim 推进就绪节点；通信只有在实际前驱完成后才注入 ns-3 网络。

记录	关键内容
请求与路由	请求、token、层、上下文、源 rank、专家选择、来源与 seed
计算依赖图	节点身份、rank、声明计算时间、前驱；包括 attention、专家和首尾阶段
逻辑通信	EP 组、轮次、层、阶段、源/目的 rank、payload 字节、逻辑消息身份
物理映射	专家→rank→GPU→服务器→NIC；交换机连接、链路速率与传播时延

2. 后端决定通信何时完成

同 GPU 的贡献不产生网络消息；同服务器不同 GPU 走机内分块带宽模型；跨服务器消息走原生 RDMA。两者使用同一个 ns-3 Simulator，多个 EP 组共享持续存在的网络状态，不能分别运行后把耗时相加。

接收端获得完整数据后放行消费者；发送端得到完整 ACK 后释放相应发送事务资源。数据就绪与发送回收分别记录，同一逻辑传输只发送一次。

> 固定发包时间的重放可用于单独测网络，但不能代替在线依赖实验。构图消耗的宿主时间计入运行成本，不计入被模拟的业务时间。

02 / 模型、输入大小与 GPU 声明

1. 近期固定模型作为可解释基线

采用 Qwen3-30B-A3B-Instruct-2507 的声明结构：48 层、隐藏维 H=2048、专家中间维 768、128 专家、Top-K=8；Q/KV heads=32/4，head_dim=128。按声明结构核算总参数约 305.3 亿，通信元素采用 BF16，即每元素 2 B。

设备声明为 H100、80 GiB，每 GPU 外部接入为 400 Gb/s。计算时间使用声明参考成本，不执行张量数值前向。更换 A100/H100 名称不会自动产生对应性能；比较 GPU 时应同时提供有来源的计算成本、容量和机内/NIC 参数。

2. batch 与上下文分别控制什么

令 B 为每 rank 每轮的活跃序列数，N 为总 GPU/rank 数。当前每条序列在每步产生一个新 token，因此全局每步 token 数 T=N×B；单个 EP 组的 token 数为 EP×B。

context=2048 表示已有 KV 的上下文长度，并非每轮输入 2048 个新 token。GQA 的 BF16 KV 为每 token 全层 98,304 B；context 改变 KV 占用和 attention 成本，不自动改变每个专家贡献的 H×2 B。

可修改对象	必须一起核对的内容
模型尺寸	层数、H、专家维度、专家数、Top-K、注意力结构与权重/KV 容量
batch	实际活跃序列、token 数、专家贡献、聚合消息大小、KV 与计算成本
GPU 类型	容量、计算成本来源、机内互连、NIC 与共享资源约束
输入阶段	Decode 与 Prefill 分开；多序列 Prefill 须有匹配的 attention 采样形状

> 近期先用完整 48 层、两轮 Decode 检查因果执行。Prefill、训练和稳定态尾延迟另设输入与验收，不能由本轮短窗口直接推导。

03 / All-to-All、EP 与副本怎么定义

1. 从专家选择得到通信量

令 C[i,j] 为源 rank i 的 token 选中的、归属于 rank j 的专家贡献数。每个贡献为 H×2=4096 B，因此 Dispatch[i,j] =C[i,j]×4096 B；Combine 沿反方向返回同尺寸结果。

当前将相同目的 rank 的贡献聚合为消息，按专家复制，不跨专家去重；零元素不发消息。这是直接成对的 All-to-All-v 参考实现，尚不能代表 NCCL 或 DeepEP 的具体算法与分层优化。

每层、每轮、每个方向的总逻辑贡献为 T×8×4096 B，包含同 GPU 项。物理网络字节必须扣除同 GPU 项，再分别统计同服务器、同 Pod 跨服务器及跨 Pod 部分。线上占用还包含报头、ACK 和重传。

2. 选择 EP 前先做容量与位置核算

EP 是专家并行，一个组内的设备分担专家。当前要求专家数可被 EP 整除，每个 rank 持有完整专家子集；128 专家的模型不能直接设为 EP1024。先核算权重、KV 和声明容量，再比较跨机字节与目的端汇聚。

配置方向	网络上要回答的问题
扩大 EP	单卡专家权重下降时，通信范围和跨服务器比例增加多少
增加推理副本	多组共享网络后，吞吐、互相干扰与完成时间如何变化
同 Pod / 跨 Pod 放置	相同组与路由下，哪些消息真正经过 Agg—Core
训练 DP	额外存在梯度同步；必须加入明确依赖图后才能研究与 EP 的竞争

3. 千卡不是千卡全互发

可使用多个较小 EP 组共享千卡物理网络。例如 EP4 对应 256 个推理副本；EP128 对应 8 个副本。EP4 的组内交换与 EP128 的组内交换是不同工作量，应分别解释，不能合并成同一条扩展效率曲线。

> 本轮 TP=PP=1，不含训练 DP 梯度 AllReduce。推理副本与训练 DP 的通信含义不同；千卡终点数量也不保证核心层有负载。

04 / 可配置网络结构与图片对应关系

1. Agg 和 Clos 不是互斥选项

Agg 是汇聚层交换机的角色；Clos 是交换机之间的连接结构。实验既要能生成 ToR—Agg 汇聚网络，也要能生成带跨 Pod Core 的三层类 Clos，并用端口、扇出和容量约束判断其实际性质。

结构	连接方式与用途
两层 Leaf–Spine	GPU→ToR→Core；Agg=0，用于较小网络或层数对照
Pod 内汇聚	GPU→ToR→Agg；Core=0，多 Pod 时不能默认互通
三层类 Clos	GPU→ToR→Agg→Core；Pod 内汇聚，Core 连接不同 Pod
Multi-rail	按 GPU 槽位/NIC 分接入组；上层可按 rail 隔离或共享
HPN 参考结构	Segment、槽位 rail、双 plane、Pod 内 Agg 与跨 Pod 电交换 Core

用户第二幅图的 OCS 替换为普通电交换 Core，不建模光路重构、重构时间或时隙调度。该结构与 HPN 在分层组织上有参考关系，但不能据此声称完整复现阿里生产网络。

2. Rail 和 plane 分别是什么

Rail 是接线分组；plane 是独立交换网络副本。每 GPU 只有单 rail NIC 且上层也隔离时，跨 rail 的 All-to-All 可能不可达。不能把 GPU 当交换机，凭空补出跨 rail 路径。

双 plane 需要明确 NIC 的端口预算和选 plane 规则。例如同一 NIC 总预算 400G，可配置两个 200G 端口；若改成两个 400G，就同时增加了硬件容量，不能将全部收益归因于双平面结构。

> 当前已有这些结构的参数化生成与审计；业务验证主要沿单 rail 三层基线推进。双平面自动分流、跨 rail 中继和故障切换须单独实现与验收。

05 / 每层几个、怎么连、带宽在哪

1. 配置项与计数关系

参数类别	公开字段及作用
部署规模	pods、segments_per_pod、servers_per_segment、gpus_per_server
接入分组	rails、planes、rails_by_gpu_slot；明确每个 GPU/NIC 接到哪里
交换机数量	tors_per_segment_per_rail、aggs_per_pod_per_group、cores_per_group
连接规则	tor_uplinks、agg_uplinks；Core 可全互连、分组或循环连接
分层带宽	access、tor_agg、agg_core、tor_core；分别设置 rate_bps、delay_ns
物理约束	NIC 总速率、各类节点端口上限，以及节点、交换机和边数量预算

令 P/S/H/G 分别为 Pod、每 Pod 的 Segment、每 Segment 的服务器、每服务器 GPU 数，R/L 为 rail/plane 数，T/A/C 为相应层的配置数量；Q 在共享上层时为 1，在按 rail 分组时为 R。

GPU=P×S×H×G；ToR=P×S×R×T×L；Agg=P×Q×A×L；Core=Q×C×L。Core 数不再乘 Pod 数。计数采用同构分层配置，当前不承诺逐 Pod 异构数量或任意逐链路覆写。

2. 修改数量时同时审计什么

检查实际端口数、各层可达性、等价路径、闲置交换机和下/上行容量比。分组 Clos 必须满足分组关系，任意增加交换机数量不保证无阻塞；不合法配置拒绝，分裂网络如实报告。

带宽按每个方向分别计算。比如某 Pod 下接 64 个 400G 端点、仅有 4 条 400G Core 上联，其接入/出口比为 16:1。这是声明容量比，不等于实测吞吐，也不能用收发相加来稀释超售。

> 链路 b/s 与机内 GB/s 的单位必须区分。当前机内参考为每 GPU 每方向 450 GB/s、两段各 100 ns、16 KiB 分块；这是共享端口抽象，尚无完整 NVLink 协议与硬件校准。

06 / 对照实验：一次区分一个原因

1. 先固定业务，再改变网络

每组网络对照重用相同模型、token、专家选择、专家放置和逻辑字节矩阵。固定路由来源与 seed，避免网络完成顺序变化后重新抽样。先小范围核验，再扩到能暴露目标瓶颈的规模。

对照组	改变什么，以及回答什么
分层容量	固定流量，分别修改接入、ToR—Agg、Agg—Core 速率；定位限制层
汇聚与类 Clos	固定 GPU 与流量，列出端口、链路和割集容量差异；判断结构收益来源
单 / 多 rail	固定可达性与总 NIC 容量后比较；未实现跨 rail 传输的条件不进入性能排名
单 / 双 plane	固定总接入预算，明确选 plane 策略；分离多路径与容量增加的作用
batch	B=1/4/8，报告 token、字节、包数与计算变化；不将负载增长称为排队优化
EP 与放置	固定路由，改变组大小或同/跨 Pod 放置；报告复制、通信范围和容量变化

2. 避免混淆结构与资源数量

等成本、等端口和等割集容量是不同口径。每次明确选择一种主要约束，并同时列出其他资源差异。现有四套千卡结构的交换机、端口和带宽并不相同，直接比较总耗时不能证明哪一种结构更好。

带宽对照还需控制传输与拥塞参数。可先做协议参数保持不变的敏感性实验，再做阈值随容量匹配的实验；两者回答的问题不同，不能悄悄联动后称为仅改带宽。

3. 优先证伪，保留无收益结果

若增加 Core 带宽没有缩短业务完成，先检查跨 Pod 字节是否足够、等待是否位于关键依赖上，以及目的端或专家计算是否遮蔽了收益。保留无收益结果，不人为制造热点来维持预期。

> 本页是拟开展的机制对照，不表示整张矩阵已经执行。通信算法的层次化、去重和调度优化属于后续独立变量，必须先核对字节与依赖语义。

07 / 热点：从专家分布到网络汇聚

1. 为什么不能只用均匀随机路由

MoE 的专家选择可能偏斜，但专家热度不自动等于网络热点：同一热门专家若在本 GPU、同机或跨 Pod，会产生不同流量；多个 token 同时到达还可能形成目的端瞬时汇聚。

当前合成均衡与热点条件只用于控制变量。真实输入候选为 core12345/MoE_expert_selection_trace；原始数据尚待取得与核验，不能把合成结果当成该数据集的发现，也不能从推理路由推断训练分布。

分析步骤	输入、动作与预期产物
来源核验	确认模型、训练/推理阶段、层、专家编号、Top-K、batch 与时间顺序
热度分析	每层计数、最大/均值、变异系数、空闲专家比例及热点持续性
通信重建	加入明确的 token 源 rank 与专家放置，生成逐对字节矩阵
物理投影	统计目的 GPU/NIC、机内、同 Pod 与跨 Pod 负载；核对实际路径
配对比较	原始顺序、保留边际热度的重排与均衡基线，分离热度和同时性

2. 数据缺项怎么处理

缺源设备信息时只能直接分析专家热度；若要研究网络，须补充有标记的 rank/放置假设。缺时间顺序时不能研究热点持续性。不同模型层数或专家数不直接套入当前 Qwen3 结构，需先建立有效映射或更换模型配置。

3. 把计算热点与网络热点分开

第一组保持同一路由和专家计算成本，仅改变放置，观察网络流量与完成；第二组保持物理输入，改变有依据的专家计算成本，观察计算等待。专家变热时若计算量和网络同时变化，应明确两者贡献。

> 接收队列峰值或热门专家计数只能提示竞争位置。要解释业务拖慢，仍须追踪实际占用者、放行事件及后继依赖。

08 / 千卡扩展与实际等待时间

1. 两种规模变化分别报告

一类为单副本 EP 随 GPU 数增大，例如 16/32/128 卡、B=1；此时全局 token、EP 与拓扑同时变化。另一类保持 EP 不变、增加副本，例如 EP4 下 256/512/1024 卡；此时多个组共享网络，负载随副本数增大。

两类不能画成同一条强扩展曲线。固定全局 token 的实验又是另一口径；需明确不同规模对应的 batch、放置及网络总容量。

2. 必须分开的时间口径

指标	测量与解释
仿真内部时间	网络与业务事件的 finish_ns，回答被模拟业务用了多久
Worker 墙钟时间	从初始化、构图到后端执行和结果写出，回答本机实际等多久
完整命令时间	公共运行命令的开始/结束；还可能包含准备与自动校验
独立校验时间	单独调用检查命令时测量；不能把所有时间差都称作校验成本
内存与产物	进程树采样峰值 RSS、产物体积、消息/图节点数；标明采样口径

3. 有界执行与增长趋势

沿小规模→百卡→256→512→1024 分级观察；每例预先声明墙钟、内存、磁盘和模拟时间上限。达到预算即停止，保留日志，不自动加限额重跑。千卡是否完成与增长趋势是否可测是两个验收问题。

超时点写为“超过预算仍未完成”，作为右删失数据，不能画成在预算时刻完成。图中按实现版本、EP 和负载口径分组；只对同版本可比完成点计算增长比。外推单独标为预测，不替代实测。

> 趋势报告同时列宿主机器、构建、源码/依赖版本、并发背景、预算与状态。一次运行只支持一次实测；若估算整张矩阵成本，注明顺序执行与每例耗时假设。

09 / 正确性、归因与最终交付

1. 先验证执行，再解释机制

阶段目标	验收依据与产出
输入正确	模型/EP 合法、容量声明、拓扑端口与可达性；保存配置和审计
网络正确	单流、同机汇聚、跨 Pod 路径；逐消息数据就绪/事务回调恰好一次
联合执行正确	全层与多轮实际推进、消费者不早于数据就绪、机内/跨机字节守恒
规模成本清楚	保存完成/超时及资源记录，形成可比较的等待时间曲线
机制证据成立	相同流量下改一个资源，定位等待与后继变化，报告有效或无收益结果

2. 网络指标怎样连接业务

记录消息就绪、发起、完整接收与 ACK，逐层汇总线上字节、忙碌时间和队列。先用跨割集字节/容量给必要服务量下界，再追踪超过下界的等待。不能把所有流完成时间相加充当业务延迟。

当前 summary 观测可支持队列峰值检查，不能提供完整队列时序或独立证明长尾因果。需要归因时在预算内补采详细窗口或缩小场景。短至两轮的功能实验不报告稳定态 p99。

3. 复现与阶段产出

每例保存有效配置、路由来源/seed、源码与依赖提交或补丁哈希、完整命令、预算、拓扑审计、任务图、结果、校验、资源记录及绘图源。平台与实验分开维护；本地修改与提交，不推送仓库。

近期产出为可审计基线、等待成本报告和分层瓶颈对照；中期引入真实专家路由，比较放置与结构；长期在实机校准及强基线支持下提出一项 MoE 网络优化，沉淀工具、基准和论文。规模扩大本身不作为机制创新。

> 建议优先审阅：①目标集群的每层数量和容量预算；②先做哪项分层网络对照；③真实路由与硬件校准的来源。方法审定后再据预算展开矩阵。